

RSSI Fingerprint Localization Method Based on WiFi

Gao Wei¹, Wang Kedong¹

1. School of Astronautics, Beihang University, Beijing, China

1. gaowei1515@foxmail.com

Abstract: Although satellite navigation has been widely used, it is difficult to apply in indoor and other signal-blocked environment. With the popularization of mobile Internet, location-based application has become the most basic requirement. Therefore, how to provide accurate and reliable location information for indoor users has been widely and deeply studied, which is a hot issue in the field of navigation. In this paper, the algorithm of indoor navigation and localization is studied. Aiming at RSSI fingerprint localization methods based on WiFi, the mathematical principles of several typical matching, dimension reduction or classification algorithms are analyzed, such as KNN, WKNN, PCA, K-means and Bayes. The performance including the localization accuracy, amount of computation and stability of these methods and their combination algorithms in fingerprint location is also analyzed theoretically. The theoretical analysis shows that the localization accuracy and stability of WKNN and Bayes methods are better. At the same time, after the follow-up Kalman filtering processing, they can effectively slide the localization results and reduce the random error.

Keywords: indoor localization; RSSI fingerprint; Bayes estimation

基于WiFi的RSSI指纹定位方法

高威¹, 王可东¹

1. 北京航空航天大学, 北京, 中国, 100191

1. gaowei1515@foxmail.com

【摘要】尽管卫星导航已经得到了广泛应用, 但其很难应用于室内和其它信号受遮挡的环境中, 而随着移动互联网的普及应用, 基于位置的应用已经成为最基本的需求, 因此, 如何为室内用户提供精确可靠的位置信息得到了广泛深入的研究, 是导航领域的热点问题。本文就室内导航定位问题展开算法方面的研究, 针对基于WiFi的RSSI指纹定位这一基本原理, 分析了KNN、WKNN、PCA、K-means、Bayes等几种典型的匹配、降维或者分类算法的数学原理, 从理论上对比分析这几种定位算法及其组合方法的定位精度、计算量、稳定性等性能。理论分析表明, WKNN和Bayes方法的定位精度和稳定性都较好, 同时在经过后续的Kalman滤波处理后, 能够有效地平滑定位结果, 减小随机误差。

【关键词】室内定位; RSSI指纹; Bayes估计

1 引言

利用Wifi在传播过程中经过不同的区域会产生信号衰减这一特性, 依据接收信号强度指示(Received Signal Strength Indication, RSSI)建立强度指纹库, 在实时定位阶段用实时测得的信号强度与先前存储的数据做匹配比对, 得到位置估计结果的方法即基于WiFi的RSSI指纹定位方法。想要应用这一方法一是要建立离线阶段的指纹数据库, 二是设计在线阶段的匹配和定位算法。其中后者应用的主要方法有传统模式识别中的K近邻算法(K-Nearest Neighbor, KNN)、K加权近邻算法(Weighted K-Nearest Neighbor, WKNN)、主成分分析法(Principal Component Analysis, PCA)、K均值聚类法(K-Means Clustering Algorithm)、BP神经网络法、Bayes估计法、卡尔曼滤波等, 部分学者在上

述原始相关算法的研究基础上针对一些具体问题做了相关研究和改进。

文献[1]针对KNN算法中在线点与离线点之间欧式距离的维度大的问题, 给每个RSSI量测设定阈值并舍弃部分AP维度, 减小指纹匹配的计算量。文献[2]探讨了不同的K值对WKNN算法定位精度的影响, 实验表明随着K值的增大, 定位精度呈现出上升的趋势, 但是到达一阈值后又会随之下降。文献[3]提出对在线点和离线点的欧式距离的均值作为阈值来动态判断K的取值。

文献[4]提出利用PCA方法先对数据库进行主成分提取, 白化RSSI数据库, 然后利用K-Means聚类方法, 相比不对数据库进行PCA白化和K-Means聚类的方法其精度有一定程度的提高。文献[5]针对K-Means聚类容易受初始聚类中心选取导致聚类易收

致于局部最优点导致定位精度下降的问题,提出基于RSSI欧式距离优化初始聚类中心的算法。

文献[6]针对Bayes估计中似然函数和先验概率如何取值的问题提出了计算方法,并运用状态转换法根据定位结果的不同动态调整先验概率的计算公式,消除传播误差的影响。文献[7]针对RSSI在多次量测时易受环境干扰而波动的问题,对RSSI进行状态建模和卡尔曼滤波,减小原始RSSI数据采集过程中的噪声,使离线数据库建立更加准确。

2 定位算法分析

考虑环境中的WiFi热点即AP个数为 n ,可以表示为集合 $A = \{a_1, a_2, \dots, a_n\}$,离线位置共有样本点 m 个,表示为集合 $L = \{l_1, l_2, \dots, l_m\}$,每一个位置 l_i 一一对应其位置坐标 (x_i, y_i) ,也即 $l_i \leftrightarrow (x_i, y_i)$ 。每一个点的RSSI指纹为 n 维行向量,表示为 $s = [s_1, s_2, \dots, s_n]$ 。这样离线的RSSI指纹数据库就可以表示成 $m \times n$ 维的矩阵形式:

$$\begin{matrix} l_1(x_1, y_1) \\ l_2(x_2, y_2) \\ \vdots \\ l_m(x_m, y_m) \end{matrix} \rightarrow \begin{bmatrix} rssi_1^1 & rssi_1^2 & \cdots & rssi_1^n \\ rssi_2^1 & rssi_2^2 & \cdots & rssi_2^n \\ \vdots & \vdots & \ddots & \vdots \\ rssi_m^1 & rssi_m^2 & \cdots & rssi_m^n \end{bmatrix} \quad (1)$$

在线阶段为 $0 \sim t$ 时间段内,每隔 ∇t 时间进行一次RSSI量测并定位,得到一系列量测值 $s(0) \sim s(t)$,并以此量测为依据结合离线RSSI指纹库来确定相应的位置轨迹 $l(0) \sim l(t)$ 。

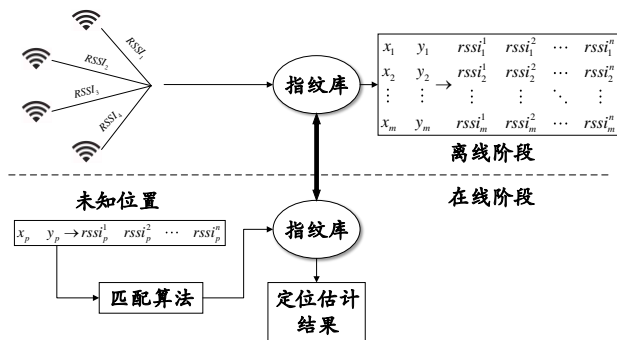


Figure 1. the process of fingerprint localization method

图 1. 指纹定位方法的流程

2.1 KNN 与 WKNN 算法

KNN 算法应用到 RSSI 指纹定位问题中,遍历指纹库中与待定位点欧式距离最小的 K 个点并将其位置坐标取平均值就能得到待定点的估计位置^[8]。如果考虑取平均时根据欧式距离大小进行加权即得到WKNN 算法。

用数学语言描述如下,在 t_k 时刻量测得到的RSSI量测值为 $s(t_k)$,则该时刻量测与指纹库中第 i 个位置指纹的欧式距离 $D_i(t_k) = \|s(t_k) - s_i\|$,遍历指纹库中 m 个指纹数据后,将 m 个欧式距离 $D_1(t_k) \sim D_m(t_k)$ 按从小到大的顺序排列并取前 K 个记为 $d_1(t_k) \sim d_K(t_k)$,与之对应的位置点依次记为 $l_1(t_k) \sim l_K(t_k)$,于是利用KNN 算法估计出的 t_k 时刻的位置可以表示成 $\hat{l}(t_k)(\hat{x}(t_k), \hat{y}(t_k))$,其中

$$\begin{cases} \hat{x}(t_k) = \frac{1}{K} \sum_{j=1}^K x_j(t_k) \\ \hat{y}(t_k) = \frac{1}{K} \sum_{j=1}^K y_j(t_k) \end{cases} \quad (2)$$

其中 $\hat{x}(t_k)$ 、 $\hat{y}(t_k)$ 表示估计的位置坐标, $x(t_k)$ 、 $y(t_k)$ 表示前 K 个位置点对应的位置坐标。

如果是WKNN 算法,那么(2)式变成了

$$\begin{cases} \hat{x}(t_k) = \sum_{j=1}^K \omega_j(t_k) x_j(t_k) \\ \hat{y}(t_k) = \sum_{j=1}^K \omega_j(t_k) y_j(t_k) \end{cases} \quad (3)$$

其中 $\omega_j(t_k)$ 表示相应数据点的权重系数,是距离 $d_1(t_k) \sim d_K(t_k)$ 的函数,距离越小相应的权重系数越大,即 $\omega_j(t_k) = f(d_j(t_k))$,于是如何选取权重函数就成为影响WKNN 算法性能的一项重要指标。

权重函数的选取主要有两种:一种是反比例函数,一种是高斯函数,反比例函数由于随距离衰减过快,所以经常只有距离最近的几个点起到加权作用,而高斯函数能克服反比例函数的缺点,通过选取标准差参数使曲线保持良好的性质,真正起到合适的加权效果。

2.2 K-Means+WKNN 算法

K-Means算法是一种应用广泛的非监督的聚类方法。其基本思想是让类内的相似性测度尽可能地大,而类间的相似性测度尽可能地小,在不断地迭代更新中让各类的划分趋于稳定^[9]。针对RSSI指纹定位这一研究的具体问题,K-Means算法就是从指纹数据的层面上将 m 个指纹数据聚成 k 类,每一类在空间上可能具有位置相近等特点,在相似性测度方面具有尽可能大的特点。利用K-Means算法进行聚类的步骤如下:

①输入 m 个指纹数据和聚类个数 k ,并随机选择 k 个指纹作为初始的聚类中心 $C = [s_1, s_2, \dots, s_k]$ 。

②针对剩下的 $(m - k)$ 个指纹,分别计算其到每个类中心的距离并表示成矩阵的形式

$$D = \{d_{ij} | i = 1, 2, \dots, (m - k), j = 1, 2, \dots, k\}$$

其中 d_{ij} 表示第 i 个指纹到第 j 个类中心之间的距离,找到距离每个指纹最近的类中心,并将该指纹归

入这个类中，从而得到一次聚类的结果。

③根据一次聚类的结果，重新计算每个类的中心，方法为对该类所有RSSI指纹求取均值，得到新的 $c^* = [s_1^*, s_2^*, \dots, s_k^*]$ 聚类中心。

④如果相邻的两次聚类中心集合 c 和 c^* 满足一定的收敛条件如 $\|s_i - s_i^*\| < \varepsilon, i = 1, 2, \dots, k$ ，即两次聚类得到的类中心的距离均在一个较小的阈值之内，则认为聚类收敛，当前 c^* 中包含的 G_1, G_2, \dots, G_k 为最终形成的聚类结果。否则令 $c = c^*$ ，也即更新聚类中心，返回步骤②继续。

利用 K-Means 算法得到训练好的离线数据库和相应的类，在线测量得到 RSSI 数据之后，首先利用到各个类中心点的欧式距离判断该位置点属于哪一个类，再在类内利用 WKNN 算法得到最终的定位结果。在离线阶段利用 K-Mean 算法相当于对数据库进行分类预处理，后续在线过程中的匹配数据库规模就小很多，有助于在线阶段计算量的减少。K-Means 算法问题在于其聚类不是稳定的，初始点的选取对聚类结果有较大影响从而影响最终的定位。

2.3 PCA+WKNN 算法

PCA 主成分分析方法，主要作用是对高维的数据特征进行降维处理。在 RSSI 指纹定位的问题中数据特征维度即 AP 个数，降维意味着不重要的 AP 维度会被去除掉，只保留最重要和关键的特征维度，从而达到减小计算量的目的^[4]。降维往往会导致一定程度的信息损失，但是如果信息损失的度可以接受而计算开销和时间开销能够大大降低，那也是可以接受的。

PCA 的主要思想是将 n 维数据映射到相互正交的 k 维主成分上 ($k < n$)，并让该 k 维特征尽可能多地包含原有的 n 维数据特征所蕴含的信息，蕴含信息量多少用方差来衡量因此选择方差最大的前 k 维，前 k 维主成分之后的特征维度方差很小，包含的信息也是最少，从而做到特征降维的效果。

利用 PCA 方法的步骤如下：

①对所有的样本进行中心化处理， n 维样本集表示成 $s = [s_1^T, s_2^T, \dots, s_m^T]^T$ ，则中心化处理后的样本 s_i 可以写成 $s_i = s_i - \frac{1}{m} \sum_{j=1}^m s_j$

②计算中心化处理后的协方差矩阵 $cov = ss^T$

③对协方差矩阵 ss^T 进行特征值分解，取最大的 n' 个特征值对应的特征向量 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_{n'}]$

④对原来的 n 维样本集转化为新的降维后的样本集 $s_i' = S\alpha$

PCA 算法的优点主要是仅仅依赖方差衡量信息

量，不受其他因素的影响，且计算方法较为简单易于实现。缺点是如果样本集原本的各个维度互相之间相关性较小，每个维度包含的独立的信息较多，那么强行使用 PCA 降维方法会导致原有数据库信息的大量丢失，对后续数据处理不利。同 K-Mean 算法一样，PCA 算法也是在离线阶段对数据进行事先处理，有助于在线阶段计算量的减少。

2.4 Bayes 算法

基于 Bayes 算法实现定位，其原理为贝叶斯定理，

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (4)$$

其中 $P(A|B)$ 表示在 B 发生的条件下， A 会发生的概率，也即 A 的验后概率，而 $P(A)$ 是 A 的先验概率。

基于该原理实现 WiFi 定位，离线的 m 个位置点可以表示成集合 $L = \{l_1, l_2, \dots, l_m\}$ ，在线阶段 t_k 时刻的 RSSI 量测值为 $s(t_k)$ ，那么通过贝叶斯公式可以计算出指纹库中每一个点的验后概率

$$P(l_i | s(t_k)) = \frac{P(s(t_k) | l_i) \times P(l_i)}{P(s(t_k))}, i = 1, 2, \dots, m \quad (5)$$

其中 $P(l_i | s(t_k))$ 表示在已知 t_k 时刻的 RSSI 量测值为 $s(t_k)$ 的情况下该点为 l_i 的可能性有多大，显然这个概率越大，在线测量点的位置离 l_i 点位置更近的可能性越大。这里利用 WKNN 的思想对概率进行从大到小的排列并将相应的点重新记为 l_1, l_2, \dots, l_k ，选取前 K 个最大的概率对相应的位置坐标进行加权得到估计的位置坐标。

$$\begin{cases} \hat{x}(t_k) = \sum_{j=1}^K P(l_j | s(t_k)) x_j(t_k) \\ \hat{y}(t_k) = \sum_{j=1}^K P(l_j | s(t_k)) y_j(t_k) \end{cases} \quad (6)$$

于是利用贝叶斯方法解决该问题的关键在于求验后概率 $P(l_i | s(t_k))$ ，利用贝叶斯公式可知 $P(l_i | s(t_k))$ 可以表示成似然概率 $P(s(t_k) | l_i)$ 、先验概率 $P(l_i)$ 、边缘概率 $P(s(t_k))$ 三项的形式。其中第一项 $P(s(t_k) | l_i)$ ，表示已知各个指纹样本参考点 l_i 的情况下获得的 RSSI 位置指纹 $s(t_k)$ 的概率，由于各个 AP 收信号强度互相独立，所以

$$\begin{aligned} P(s(t_k) | l_i) \\ = P(s_1(t_k) | l_i) \times P(s_2(t_k) | l_i) \cdots \times P(s_n(t_k) | l_i) \end{aligned} \quad (7)$$

可以认为每一个 AP 在参考点 l_i 处的 RSSI 概率分布近似为高斯分布，于是每一小项都可以用高斯概率分布的式子表示为^[8]：

$$P(s_j(t_k) | l_i) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(s_j - \mu)^2}{2\sigma^2}} \quad (8)$$

其中 μ 表示在参考点 l_i 处第 j 个 AP 产生的 RSSI 值, 可以认为是离线建立的 RSSI 指纹数据库中对应的值, σ 表示该 RSSI 值的标准差为正态分布参数。

解决了 $P(S(t_k)|l_i)$, 还剩下 $P(l_i)$ 、 $P(S(t_k))$ 两项, 其中 $P(S(t_k))$ 对每一个离线点来说是固定的常值其作用效果是相同的, 不影响最后的判断, 而 $P(l_i)$ 既可以将其视为常值, 也可以考虑先前时刻定位结果对概率 $P(l_i)$ 的影响。由于物体运动的连续性, 当前时刻的位置出现在上一时刻附近的可能性更大, 于是借鉴衰减滤波的思路, 离当前时刻越久远位置估计点, 在计算 $P(l_i)$ 时的所占的概率权重越小。将两种因素综合考虑进去, 如果将 $0 \sim t_{k-1}$ 时刻的估计位置记为 $l_0^p, l_1^p, \dots, l_{k-1}^p$, 这里定义 $P(l_i)$:

$$P(l_i) = \frac{1}{k} \sum_{j=0}^{k-1} [e^{j \times \text{dist}^{-1}(l_i, l_j^p)}] \quad (9)$$

其中 $\text{dist}(l_i, l_j^p)$ 表示参考点 l_i 到 t_j 时刻估计位置 l_j^p 的距离, 前面的系数 e^j 即权重系数, 距离当前时刻越久远, e 的指数上标越小, 意味着其概率权重越小。在初始时刻由于没有先前时刻估计的位置因此可以认为每一个点的 $P(l_i) = 1$ 。

从 Bayes 估计的核心公式(5)可以看出似然概率 $P(s_i(t_k)|l_i)$ 和先验概率 $P(l_i)$ 对最终的验后概率 $P(l_i|S(t_k))$ 的作用应该是同等的, 为了避免用公式(7)算出来的似然概率和用公式(9)算出来的先验概率在数量级上不同导致对验后概率的贡献度不同, 这里对似然概率 $P(s_j(t_k)|l_i)$ 和先验概率 $P(l_i)$ 做归一化处理, 即:

$$P'(S(t_k)|l_i) = \frac{P(S(t_k)|l_i)}{\sum_{i=1}^m P(S(t_k)|l_i)}, P'(l_i) = \frac{P(l_i)}{\sum_{i=1}^m P(l_i)} \quad (10)$$

这样处理之后保证

$$\sum_{i=1}^m P'(S(t_k)|l_i) = 1, \sum_{i=1}^m P'(l_i) = 1 \quad (11)$$

即所有离线点的似然概率加起来为 1, 所有离线点的先验概率加起来也为 1, 保证二者在计算验后概率中的同等贡献度。

由于前面的几种基于近邻法定位思想的只需要遍历一次离线数据库, 求得每个离线点到在线点的欧式距离即可, 而上述 Bayes 估计方法则需要遍历两次, 第一次是计算每一个点的似然概率 $P(S(t_k)|l_i)$, 第二次是利用记忆衰减的原理计算每一个点的 $P(l_i)$, 因此在时间开销上 Bayes 算法会更大一些。Bayes 算法考虑到了用户在空间中运动的拓扑结构, 这是前面几种基于近邻思想的算法没有考虑到的问题。

2.5 卡尔曼滤波

由于通过匹配算法得到得到的位置没有考虑到随

时间推移物体的运动规律, 只是单纯地将每个时刻的 RSSI 量测值当作孤立的数据与数据库中数据进行匹配定位。可以考虑对物体的运动进行建模, 建立物体运动的量测方程, 而将利用 RSSI 量测信息结合前面各类定位方法的定位结果看成观测量, 建立观测方程, 通过卡尔曼滤波的方法得到融合后定位结果。由于融合了物体运动的信息, 理论上比单纯利用 RSSI 量测给出的定位结果精度会更高。

考虑线性系统的状态方程和量测方程

$$\begin{aligned} X_k &= \Phi_{k-1} X_{k-1} + W_{k-1} \\ Z_k &= H_k X_k + V_k \end{aligned} \quad (12)$$

其中 Φ_{k-1} 为 t_{k-1} 时刻至 t_k 时刻的状态转移矩阵, V_k 和 W_k 分别为量测噪声阵和状态噪声阵, 且均为 0 均值互不相关的白噪声, 满足

$$\begin{aligned} E(W_k W_{j0}^T) &= Q_k \delta_{kj} \\ E(V_k V_j^T) &= R_k \delta_{kj} \\ E(W_k W_j^T) &= 0 \end{aligned} \quad (13)$$

那么状态 X_k 的估计 \hat{X}_k 按照下述方程求解

状态预测 $\hat{X}_k(-) = \Phi_{k-1} \hat{X}_{k-1}(+)$

误差协方差阵预测 $P_k(-) = \Phi_{k-1} P_{k-1}(+) \Phi_{k-1}^T + Q_{k-1}$

增益阵 $K_k = P_k(-) H_k^T [H_k P_k(-) H_k^T + R_k]^{-1}$

状态修正 $\hat{X}_k(+) = \hat{X}_k(-) + K_k [Z_k - H_k \hat{X}_k(-)]$

误差协方差修正 $P_k(+) = (I - K_k H_k) P_k(-)$

具体运用到本问题中, 选取状态变量为位置和速度, 观测量为通过前面的匹配方法得到的位置, 即

$$X = [x, y, V_x, V_y]^T \quad (14)$$

对状态建模的准确程度会显著影响到卡尔曼滤波器的性能, 一个简单的建模可以认为当前时刻的位置等于上一时刻的位置加上当前上一时刻的速度乘以滤波周期。这样状态转移矩阵和观测矩阵可以写成:

$$\Phi = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, H = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \quad (15)$$

如果物体运动规律比较复杂可以考虑更切合实际的特定模型, 得到更好的 Φ 阵和 H 阵以期取得更好的效果。初始状态 X_0 利用第一次匹配得到的观测量得到, R 阵和 Q 阵的选取取决于对状态建模的信任程度和对观测过程的信任程度。 R 阵选取越大, 说明观测方程的量测噪声较大, 滤波器将更加青睐于通过运动建模得到的定位结果; Q 阵选取越大, 说明运动建模的噪声较大, 滤波器将输出更加接近匹配算法计算出的观测轨迹结果。

3 定位算法总结

通过上述几种算法的理论推导,最后总结一下几种方法的优缺点。

KNN 算法和 WKNN 算法都利用离线点与在线点的欧式距离作为二者的相似性测度,运用近邻的思想与求取位置平均的思路,其中 WKNN 由于根据欧式距离的大小在求平均时做加权,只要权重函数取得恰当效果都会比 KNN 算法好。

K-Means+WKNN 算法和 PCA+WKNN 算法都属于算法的组合,本质上都是先在离线阶段对数据库做预处理,然后在线阶段使用 WKNN 算法。显然预处理之后原有数据库的信息会有损失,但是同时计算量也会有下降,在数据库规模很大时可以应用。

Bayes 算法利用验后概率来描述离线点与在线点之间的相似性程度,并且与基于近邻法思想的上述几种算法不同,在计算验后概率的改进公式结合了先前时刻的定位结果,因此对物体的运动信息利用更加全面,其在算法时间开销上会更大,但与此同时会带来定位精度的提高。

Kalman 滤波作为一种建模与量测结合的手段,能够起到对前面几种方法定位结果的平滑作用,尤其是在对物体的运动建模准确的情况下能有效减小前面几种量测定位方式的随机误差。

References (参考文献)

- [1] Zhang Xiaoliang, Zhao Ping, Xu Guanying, Lin Riming, Research of indoor positioning based on a optimization KNN algorithm[J], *Electronic Design Engineering*, 2013, 21(07):44-46 (Ch).张晓亮,赵平,徐冠青,林日明,基于一种优化的 KNN 算法在室内定位中的应用研究[J], *电子设计工程*, 2013, 21(07):44-46.
- [2] Bahl P, Padmanabhan V N. RADAR: An in-building RF-based user location and tracking system[C]. INFOCOM 2000. Nineteenth Annual Joint Conference of the IEEE Computer and Communications Societies. Proceedings. IEEE. IEEE, 2000.
- [3] Shin B, Lee J H, Lee T, et al. Enhanced weighted K-nearest neighbor algorithm for indoor Wi-Fi positioning systems[C]. 2012 8th International Conference on Computing Technology and Information Management (NCM and ICNIT). IEEE, 2012.
- [4] Yang Mingji, Liu Kaiyi, Shao Dan, PCA clustering algorithm for indoor positioning in WLAN[J], *Telecommunications Science*, 2016, 32(07):21-26 (Ch).杨明极,刘恺悻,邵丹,用于 WLAN 室内定位的 PCA 聚类算法[J], *电信科学*, 2016, 32(07):21-26.
- [5] Hou Fangxing, Zhou Qinghua, An optimization method of WLAN positioning based on improved fingerprint clustering[J], *Telecommunication Engineering*, 2018, 58(11):1339-1344 (Ch).方行,周庆华,基于改进指纹聚类的 WLAN 定位优化方法[J], *电讯技术*, 2018, 58(11):1339-1344.
- [6] Xiang Z, Song S, Chen J, et al. A wireless LAN-based indoor positioning technology[J]. *IBM Journal of Research and Development*, 2004, 48(5.6):617-626.
- [7] Tang Shikai, Gao Xue, Zuo Peng, Dou Gang, Mobile target indoor positioning algorithm based on Kalman filter[J], *China Sciencepaper*, 2017, 12(20):2301-2304 (Ch).唐士凯,高学,左鹏,窦刚,基于卡尔曼滤波的室内移动目标定位算法[J], *中国科技论文*, 2017, 12(20):2301-2304.
- [8] Zeng Mingfang, Research and implementation of WiFi indoor location algorithm based on RSSI[D], *Harbin Engineering University*, 2018 (Ch).曾明芳,基于 RSSI 的 WiFi 室内定位算法研究与实现[D], 哈尔滨工程大学, 2018.
- [9] Wang Shuting, Research on WiFi positioning Algorithm based on location fingerprint[D], *Jilin University*, 2015 (Ch).王淑婷,基于位置指纹的 WiFi 定位算法研究[D], 吉林大学, 2015.